Silero VAD contra el corte por energía (RMS) en Parakeet

Medición con voz real para la detección incremental de vishing · issue #94 (sub-issue de #87) · PLAN-VOZ-REAL.md §12 · 2026-10-29

Autor: Luciano Grosso. Medición, gráficos y redacción asistidos por Claude Opus 5.5. Código en la rama `LucianoGrosso13/silero-vs-rms-94` (`5dd0af5`). Material de desarrollo: **no cierra D09** ni elige un ASR.

En una página

Pregunta. ¿Mejora el texto que le llega al detector si un VAD de voz (Silero) decide qué es voz en lugar de la energía del bloque (RMS)? Todo lo demás quedó igual: el mismo audio, el mismo Parakeet, el mismo preaudio y el mismo corte.

Respuesta corta: no le gana al RMS en texto, pero sí ahorra trabajo en el silencio con ruidos.

- Referencia (RMS 0,008, corte 0,8 s, lo de «Probar el ASR»): **28/30** frases con etiquetas correctas y **WER 13,3 %** en la toma 2; 28/30 y 13,0 % en la toma 3.
- Silero con su umbral de fábrica (0,5) **junta frases**: 33 cierres por el tope de 10 s contra 6 del RMS, WER 20,3 % y casi el doble de audio al ASR.
- Silero con umbral 0,9 y corte 0,3 s **queda cerca pero no gana**: 28/30 y WER 16,3 % (toma 2), 28/30 y 14,0 % (toma 3), 0,36 s menos de demora, pero parte más (38 segmentos para 30 frases).
- **Donde Silero sí sirve:** 44,2 s de silencio con ruidos (G10) pasan de 28 llamadas al ASR a 0; con la tele de fondo (G08) deja de cortar cada 10 s. No frena la voz de una serie sin nadie hablando.
- Ninguna variante pasa la regla del plan (§2) y ninguna frase negativa disparó etiquetas. «Compartí pantalla» no lo pierde el corte: Parakeet escribe «Compartir la pantalla» y las reglas no reconocen esa forma.
- **Decisión:** ninguna todavía. El panel y la llamada siguen como estaban. Lo que sugiere esta medición está marcado como *propuesta sin discutir* (sección 9) y lo decide Luciano en D09.

1. Por qué probamos esto

El sistema escucha la llamada, la pasa a texto con un ASR local y un detector busca pedidos de estafa en ese texto. Parakeet, el ASR que se está probando, no es streaming: hay que cortarle el audio en frases. Quién decide dónde empieza y termina cada frase es justamente lo que se compara acá.

- **Lo que había (auditoría del 2026-10-29, §10).** `MotorPorFrases` decide voz o silencio por bloque de 40 ms comparando la energía (RMS) con un umbral. Es un detector de energía: no distingue la voz de un golpe, una respiración o una tele. Una recomendación recibida proponía Silero VAD como imprescindible; la auditoría dejó la comparación como pendiente, sin adoptarlo.
- **Lo que mostró la primera medición con voz real (§11).** Con el RMS: 30 s de silencio con ruidos (G10) mandaron 8 ruidos al ASR, que inventó «Shh. Uh-uh.»; con una serie de fondo (G08) el ruido nunca baja del umbral y las frases se cierran cada 10 s justos, cortando palabras; «Compartí pantalla» parecía perder la primera palabra en todas las tomas.
- **La hipótesis.** Un VAD entrenado para reconocer voz humana debería dejar de mandar ruidos al ASR y no comerse los inicios de palabra. Era el paso 1 del plan (§11.6) antes de tocar la llamada en vivo.

2. Contra qué lo comparamos

Se cambió **una sola cosa**: quién decide si cada bloque de 40 ms es voz. Todo lo demás es idéntico en todas las variantes.

Queda igual en todas	Valor
Audio	las 20 grabaciones con texto de `pruebas.csv` más G10 y la serie sin hablar
Modelo de ASR	Parakeet TDT 0.6B v3 int8 (sherpa-onnx 1.13.8), 2 hilos, greedy
Bloques	40 ms (640 muestras a 16 kHz), como los manda el panel
Preaudio	0,3 s de audio anterior al inicio detectado
Voz mínima	0,3 s para transcribir una frase; 1 s para el primer borrador
Borradores	cada 0,5 s, con el filtro de idioma
Tope de frase	10 s

Las variantes medidas:

Variante	Quién decide la voz	Por qué está
RMS 0,008 · corte 0,8 s (referencia)	RMS ≥ 0,008	**Referencia**: el valor inicial de «Probar el ASR» elegido por Luciano el 2026-10-29
RMS 0,003 · corte 0,9 s (panel anterior)	RMS ≥ 0,003	Contexto: lo que tenía el panel antes (y la llamada en vivo hoy)
Silero 0,5 · corte 0,8 / 0,5 / 0,3 s	Silero, umbral de fábrica	Mismo corte que la referencia y dos más cortos, porque Silero tarda en soltar la voz
Silero 0,9 · corte 0,5 / 0,3 s	Silero, umbral alto	Agregadas después de ver que con 0,5 las frases se juntaban (sección 6)

Cómo usa Silero el motor. `VadModel.is_speech()` de sherpa-onnx con el `silero_vad.onnx` oficial del release (644 KB). Silero mira ventanas de 32 ms; un bloque de 40 ms es voz si alguna ventana que terminó en él es voz. Una vez en voz, sigue en voz mientras la probabilidad no baje de *umbral − 0,15* (histéresis de sherpa). El RMS 0,008 se sigue calculando solo para marcar el fin de la voz y medir la demora igual que en la referencia.

3. Con qué datos: tu voz y el guion

Todo el audio lo grabó Luciano el 2026-10-29 entre las 19:36 y las 20:52, con «Probar el ASR» del panel, el micrófono de la Mac, en su pieza, leyendo los bloques del guion desde el celular. El panel guardó el audio entero a 16 kHz; las variantes se rehicieron offline sobre ese mismo audio, así que todas escuchan exactamente lo mismo. **El audio no está en Git** (copia `bitacora_tesis-voip-asr/experiments/voip/llamadas/`) y tampoco en este informe.

El guion. 30 frases en 6 bloques de 5: 10 con términos críticos (código, clave, CVV, token…), 5 con números y montos, 5 con bancos y apps, 5 espontáneas con jerga tucumana y 5 negativas parecidas a una estafa pero inocentes («estoy cómodo», «me duele el codo»). La referencia de cada grabación es el texto del bloque leído; Luciano no informó desvíos.

Cómo se mide. La medida principal es la que importa para la tesis: se corren las reglas del detector (`reglas.py`) sobre el texto real y sobre la transcripción, frase por frase, y una frase está OK si dan las mismas etiquetas (`REQUEST_AUTH_CODE`, `REQUEST_TRANSFER`…). Además WER y CER, demora de la frase final y, para lo que el WER no ve, segmentos, llamadas al ASR y palabras inventadas.

Grab.	T.	Condición	Bl.	Dur. (s)	Segmentos RMS / S0,5 / S0,9	Frases OK RMS · S0,9
G01	1	micrófono	1	30,1	4 / 3 / 5	5/5 · 5/5
G02	1	micrófono	2	26,0	5 / 3 / 4	4/5 · 3/5
G03	1	micrófono	3	26,9	4 / 3 / 5	5/5 · 5/5
G04	1	micrófono	4	32,8	5 / 3 / 7	4/5 · 3/5
G05	1	micrófono	5	27,6	4 / 3 / 6	5/5 · 4/5
G07	1	voz-baja	1	27,1	5 / 4 / 5	5/5 · 5/5
G08	1	ruido-tv	2	27,7	3 / 4 / 6	5/5 · 5/5
G09	1	pausas	3	41,2	12 / 9 / 12	5/5 · 5/5
G11	2	micrófono	1	33,8	6 / 5 / 6	5/5 · 5/5
G12	2	micrófono	2	26,7	5 / 3 / 7	5/5 · 5/5
G13	2	micrófono	3	26,0	4 / 3 / 5	5/5 · 5/5
G14	2	micrófono	4	30,3	5 / 5 / 6	4/5 · 4/5
G15	2	micrófono	5	31,4	5 / 3 / 7	5/5 · 5/5
G16	2	micrófono	6	34,7	6 / 4 / 8	4/5 · 4/5
G11	3	micrófono	1	27,7	5 / 4 / 7	5/5 · 5/5
G12	3	micrófono	2	26,5	5 / 3 / 6	5/5 · 5/5
G13	3	micrófono	3	27,9	6 / 4 / 6	5/5 · 5/5
G14	3	micrófono	4	26,9	5 / 3 / 6	5/5 · 4/5
G15	3	micrófono	5	26,5	4 / 3 / 5	5/5 · 5/5
G16	3	micrófono	6	29,7	5 / 3 / 6	3/5 · 4/5
G10	—	sin hablar (tele apagada)	—	44,2	10 / 2 / 0	sin texto
Serie	—	sin hablar (serie de fondo)	—	175,3	24 / 19 / 11	sin texto

Toma 1: para ajustar (G06, bloque 6, se borró del Historial antes de medir). Toma 2: para decidir. Toma 3: grabada en vivo con 0,8 s / 0,008 para confirmar con audio nuevo. G07: voz baja (salió casi al volumen normal). G08: con una serie de fondo. G09: con una pausa de ~1 s dentro de cada frase. G10 y la serie: sin nadie hablando, para ver qué se inventa. T. = toma; Bl. = bloque del guion. «S0,5» = Silero 0,5 con corte 0,8 s; «S0,9» = Silero 0,9 con corte 0,3 s.

4. Qué valores esperábamos

La regla para quedarse con un cambio (PLAN-VOZ-REAL.md §2, fijada antes de medir) se aplica en la toma 2 contra la referencia. Hay que cumplir las cuatro:

Condición	Qué pide	Con esta referencia significa
Más frases OK	al menos 2 frases más con etiquetas correctas	30/30 (la referencia tiene 28/30)
Negativas	ninguna etiqueta nueva en las frases negativas	0 etiquetas nuevas
Demora	la frase final no tarda más de +0,3 s	mediana ≤ 1,40 s
WER	no empeora más de 2 puntos	WER ≤ 15,3 %

Lo que esperábamos de cada caso (escrito en §10 y §11 antes de esta medición) y lo que pasó:

Caso	Esperábamos	Pasó
G10, silencio con ruidos	Silero ahorra el ASR sobre ruidos	**Sí.** De 28 llamadas al ASR a 0–1; de 4 palabras inventadas a 0–2
Serie sin hablar	No lo resuelve: la tele también es voz	**Confirmado.** Menos llamadas (40 → 17), mismas palabras inventadas (17 → 16–19)
G08, serie mientras habla	No lo resuelve: haría falta otro umbral	**Mejor de lo esperado.** Corta en las pausas de Luciano: 0 topes con 0,9 / 0,3
«Compartí» al inicio	Un VAD no se comería inicios	**No era el corte.** Parakeet escribe «Compartir la pantalla» (sección 7)
Calidad del texto	Igual o mejor que el RMS	**No.** Peor con 0,5; cerca pero sin ganar con 0,9
Costo del VAD	Bajo	**Sí.** 0,11 ms por bloque de 40 ms (0,3 %)

Glosario rápido

Término	Qué quiere decir acá
ASR	Reconocimiento automático del habla: pasa la voz a texto. Acá, Parakeet corriendo en la Mac, sin internet.
VAD	Detector de actividad de voz: decide si un pedazo de audio tiene voz. Silero es un VAD hecho con una red neuronal.
RMS	Energía promedio de un bloque de audio. «Voz» si supera el umbral (0,008). No distingue voz de ruido.
Corte	Cuánto silencio seguido hace falta para dar la frase por terminada y mandarla al ASR.
Segmento	Pedazo de audio que el motor manda al ASR como una frase. Lo ideal: un segmento por frase leída.
Tope	Si una frase llega a 10 s sin pausa, se corta igual. Suele cortar en medio de una palabra.
Preaudio	Los 0,3 s anteriores al inicio detectado que se agregan a la frase para no perder la primera sílaba.
WER / CER	Porcentaje de palabras / letras mal transcriptas contra el texto real. Menos es mejor.
Frases OK	Frases donde las reglas del detector dan las mismas etiquetas en la transcripción que en el texto real.
Demora	Tiempo entre que termina la voz y que la frase final está lista (offline, en la M1).

5. Resultados con referencia escrita

Variante	T2 OK	T2 WER	T2 CER	T2 segm.	T2 demora	T3 OK	T3 WER	§2
RMS 0,008 · corte 0,8 s (referencia)	28/30	13,3 %	5,5 %	30	1,10 s	28/30	13,0 %	ref.
RMS 0,003 · corte 0,9 s (panel anterior)	27/30	20,8 %	13,6 %	24	1,16 s	28/30	18,3 %	no
Silero 0,5 · corte 0,8 s	27/30	20,3 %	13,3 %	21	1,64 s	29/30	20,1 %	no
Silero 0,5 · corte 0,5 s	27/30	19,8 %	11,7 %	23	1,39 s	29/30	19,6 %	no
Silero 0,5 · corte 0,3 s	28/30	16,0 %	7,2 %	26	1,17 s	29/30	19,3 %	no
Silero 0,9 · corte 0,5 s	28/30	16,5 %	8,6 %	31	1,01 s	27/30	17,0 %	no
Silero 0,9 · corte 0,3 s	28/30	16,3 %	7,4 %	38	0,74 s	28/30	14,0 %	no

T2 / T3 = toma 2 / toma 3. OK = frases con las mismas etiquetas que el texto real (de 30). §2 = ¿pasa la regla del plan?

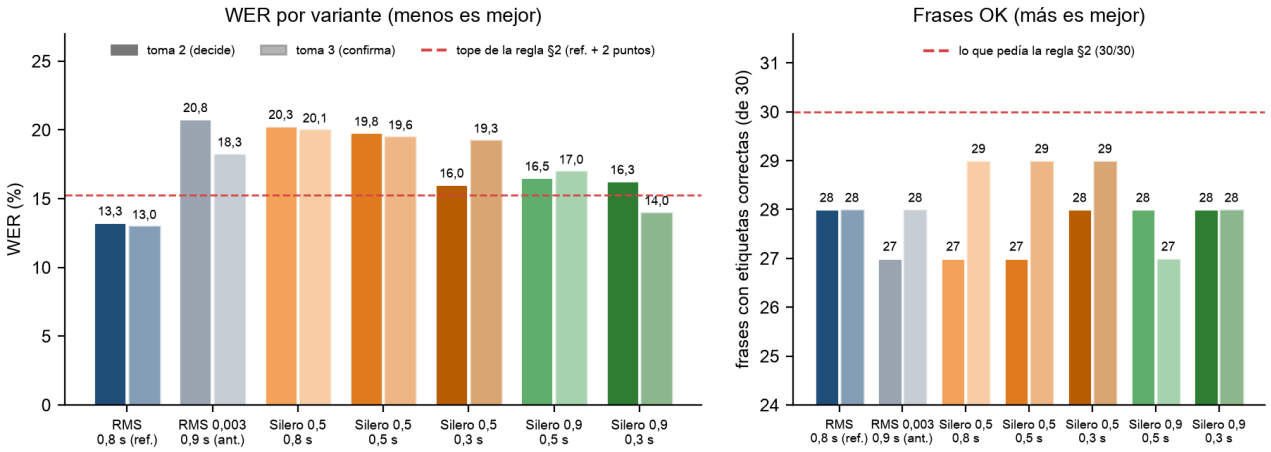


Figura 1. WER y frases con etiquetas correctas. La línea roja es lo que pedía la regla para quedarse con el cambio. Toma 2 decide; toma 3 (más clara) confirma.

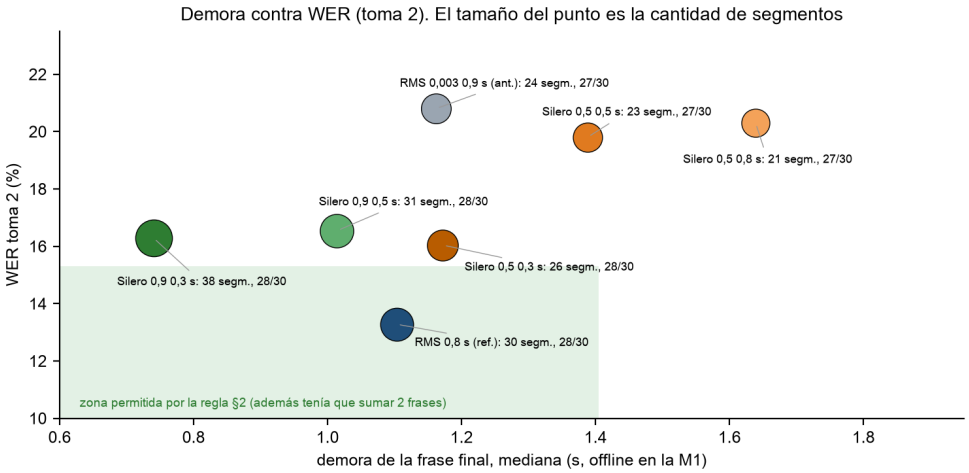


Figura 2. Cada variante en demora y WER. Ninguna cae en la zona verde con 2 frases más.

- **Ninguna variante pasa la regla.** Ninguna suma frases (+0 o −1) y todas suben el WER más de 2 puntos en la toma 2 (de +2,8 a +7,0). Ninguna negativa dispara etiquetas.
- **La toma 3 no cambia la lectura.** Silero acierta «Dame el OTP» y, con 0,9, pierde «token» (sale «toque»): son cambios del texto de Parakeet cuando recibe otro recorte de audio, no un efecto del detector.
- **Con Silero 0,9 / 0,3 en la toma 1 con micrófono** salen 20/25 frases, contra 23/25 del RMS.

6. Por qué Silero con su umbral de fábrica junta frases

Después de hablar, la probabilidad de voz de Silero no cae de golpe: baja de a poco durante 0,3 a 1 s. Con la histéresis de sherpa, una vez en voz sigue en voz hasta que baja de 0,35. Las pausas reales de Luciano entre frases son de 0,5 a 1,4 s (§11.2): muchas no llegan a verse como silencio, la frase sigue abierta y termina cerrada por el tope de 10 s, en medio de una palabra. Con umbral 0,9 hay que bajar de 0,75 para salir, y las pausas sí se ven.

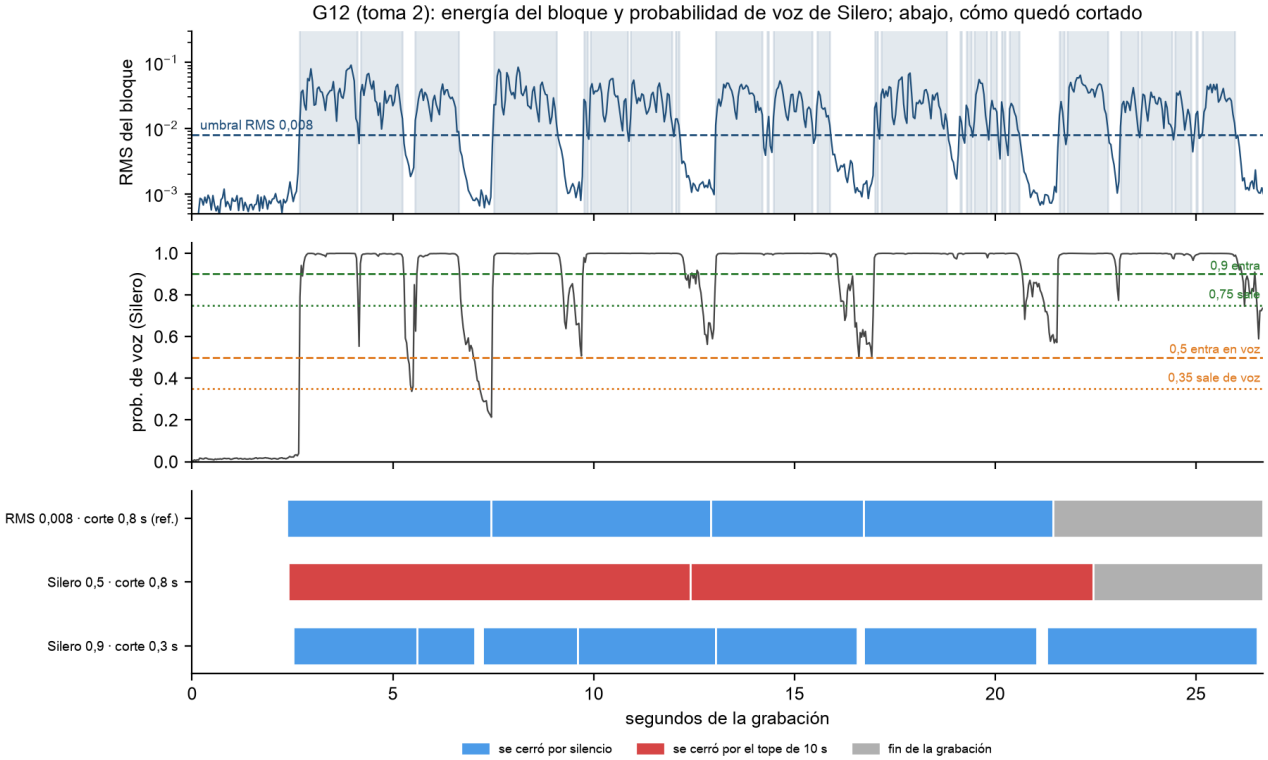


Figura 3. G12 (toma 2, bloque 2). Arriba: energía de cada bloque y el umbral RMS. Medio: probabilidad de Silero con sus umbrales de entrada (rayas) y de salida (puntos). Abajo: los segmentos que quedan con cada variante. Con Silero 0,5 las cinco frases quedan en dos tramos de 10 s cerrados por el tope.

Para elegir el 0,9 se simuló solo el corte, sin ASR, sobre las 20 grabaciones con texto (100 frases):

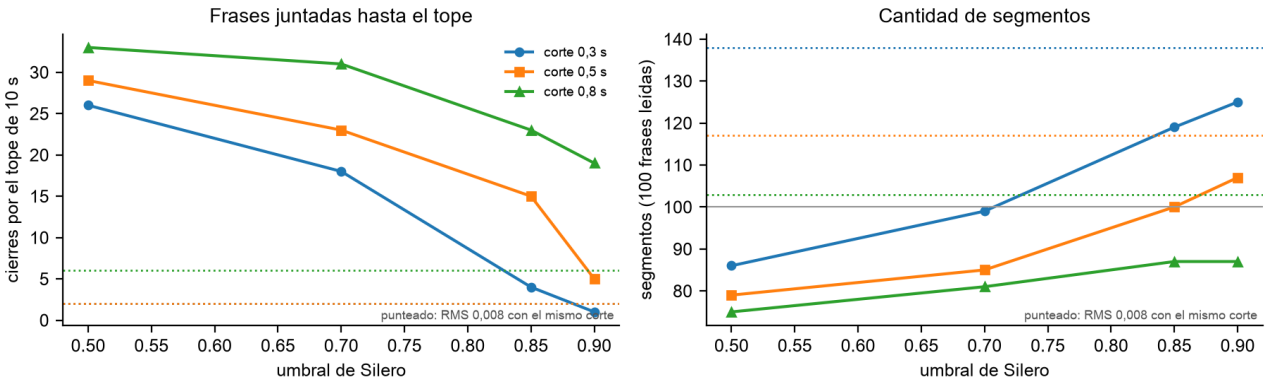


Figura 4. Simulación del corte sin ASR. Con 0,9 y corte 0,3 s queda 1 tope en 125 segmentos, casi como el RMS. El 0,9 se eligió mirando estas mismas grabaciones: falta confirmarlo con una toma nueva.

7. Lo que el WER no muestra

Grabaciones sin nadie hablando. Todo lo que sale ahí es inventado y cada llamada al ASR es trabajo de más.

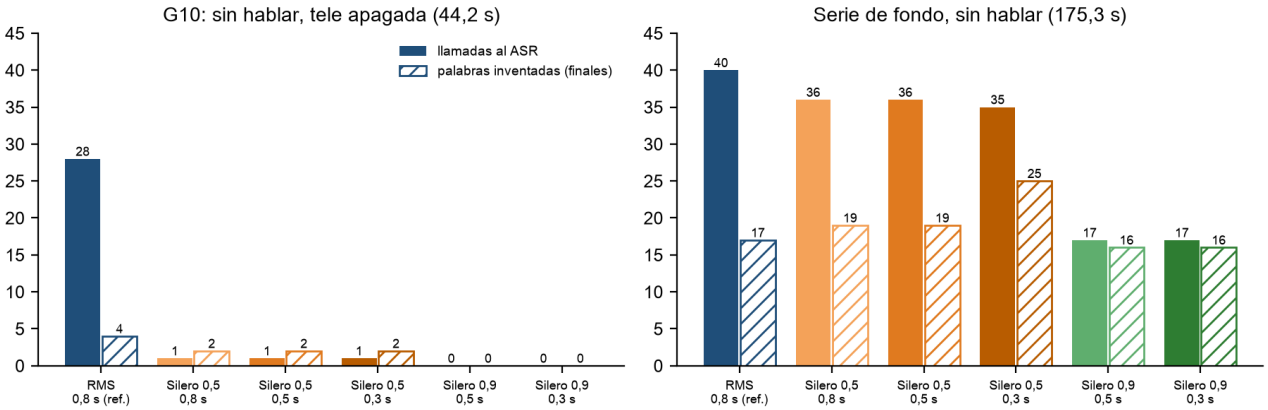


Figura 5. Llamadas al ASR y palabras inventadas en las frases finales. En G10 Silero no manda nada al ASR; con la serie llama menos pero inventa lo mismo, porque la tele es voz humana.

Grab.	Variante	Segm.	Llam. ASR	Audio ASR	Lo que salió
G10	RMS 0,008 · corte 0,8 s (ref.)	10	28	79 s	«Shh. Uh-uh.» · «He»
G10	Silero 0,5 · corte 0,8 s	2	1	2 s	«Uh uh.»
G10	Silero 0,9 · corte 0,3 s	0	0	0 s	nada
Serie	RMS 0,008 · corte 0,8 s (ref.)	24	40	165 s	«Hello» · «Well then.» · «Creo que tú tampoco. No quiero que te desmida.» · «No sé, nada.»
Serie	Silero 0,5 · corte 0,8 s	19	36	88 s	«Okay.» · «Otro intento.» · «Very good.» · «Hola.»
Serie	Silero 0,9 · corte 0,3 s	11	17	28 s	«Very good.» · «It is funky.» · «Yeah, no.» · «Yeah, this one.»

G08: hablar con la tele prendida.

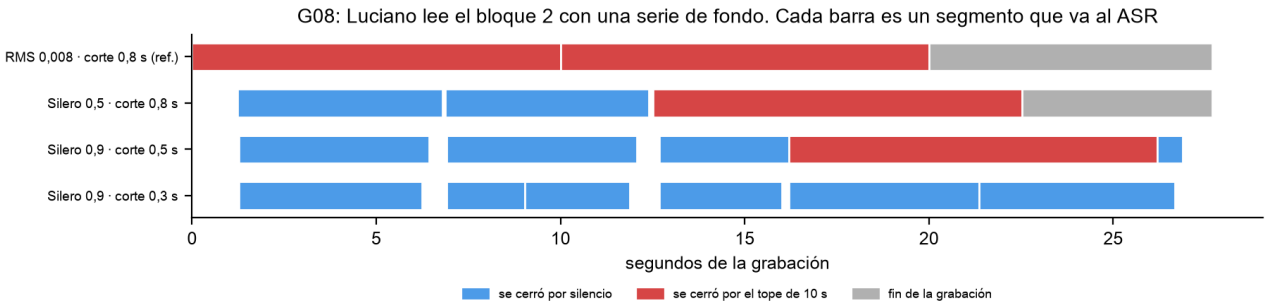


Figura 6. Con el RMS el ruido de la tele nunca baja del umbral y las frases se cortan cada 10 s. Silero reconoce las pausas de Luciano aunque la tele siga: con 0,9 / 0,3 ningún segmento llega al tope. Las etiquetas de G08 salieron 5/5 con todas las variantes.

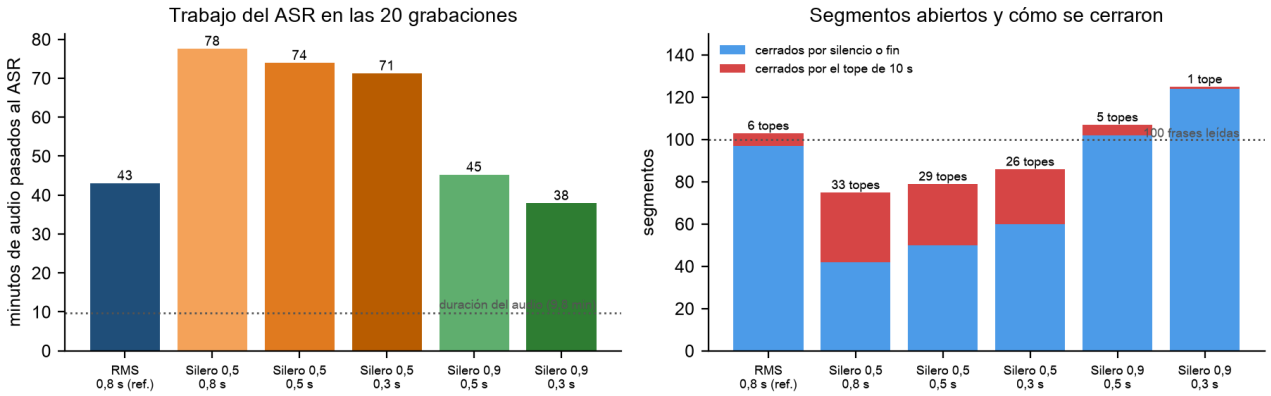


Figura 7. En las 20 grabaciones con texto (9,8 min). Cada borrador vuelve a transcribir la frase entera: con frases de 10 s, Silero 0,5 casi duplica el audio que procesa el ASR. Silero 0,9 / 0,3 queda un 12 % por debajo del RMS.

Demora y costo del detector, contra el RMS, en las 20 grabaciones:

Variante	Llega al empezar la voz	Llega al terminar la voz	Costo por bloque (mediana / p95)
RMS 0,008 · corte 0,8 s (referencia)	igual (es la referencia)	igual (es la referencia)	0,004 / 0,037 ms
Silero 0,5 · corte 0,8 s	0,04 s después (p90 0,08 s)	0,06 s después (p90 0,52 s)	0,112 / 0,248 ms
Silero 0,9 · corte 0,3 s	0,04 s después (p90 0,08 s)	0,12 s después (p90 0,40 s)	0,111 / 0,268 ms

Al empezar, Silero llega una ventana (40 ms) después del RMS: el preaudio de 0,3 s lo cubre. El costo es de CPU en la M1, no de batería: 0,11 ms por cada bloque de 40 ms, un 0,3 % del tiempo real.

Inicios de palabra y «Compartí pantalla».

- Ningún detector se come inicios de forma sistemática: sin contar el voseo que el modelo pasa a infinitivo («Hacé» → «Hacer»), falta la primera palabra en 10 de 100 frases con el RMS y en 9 a 15 con Silero, casi siempre por errores del modelo («Ñaño, al ñudo» → «Al pedo»).
- **«Compartí» no se pierde.** Parakeet escribe «Compartir la pantalla…» al principio de su propio segmento, con los dos detectores, y volver a transcribir ese segmento con 0,3 o 0,6 s más de audio previo da lo mismo.
- La etiqueta `REQUEST_REMOTE_ACCESS` se pierde por otras dos cosas: el reparto por frases de la medición deja «Compartir» en la frase anterior, y las reglas buscan «comparti pantalla», que no coincide con «compartir la pantalla». Es un riesgo de las reglas (D07, abierta), no del VAD. Corrige lo que decía el §11.5.

8. Qué está decidido y qué no

Tema	Estado
Valor inicial de «Probar el ASR»	**Decidido por Luciano** (2026-10-29, §11): 0,8 s / 0,008 con RMS. Esta medición no lo cambia.
Llamada en vivo	Sigue en 0,9 s / 0,003 con RMS. No se tocó.
Silero en el motor	Implementado como opción (`detector_voz`). **Por defecto sigue el RMS.**
Reemplazar el RMS por Silero	**No decidido.** Propuesta sin discutir (sección 9).
Elegir ASR y detector (D09)	**Abierta.** Esto es material de desarrollo con una sola voz.
Reglas y «compartir la pantalla» (D07)	**Abierta.** Las reglas no se tocaron.

9. Qué sugiere la medición

Estado: propuesta sin discutir. Decide Luciano en D09.

- **Con esta voz no hay motivo para cambiar el RMS por Silero.** Con el umbral de fábrica empeora el texto y duplica el trabajo del ASR; con 0,9 / 0,3 queda cerca pero no suma frases, sube el WER y parte más (cada segmento extra es una evaluación más del detector).
- **Silero sí sirve para no transcribir el silencio con ruidos y para cortar con una tele de fondo.** No sirve para frenar la voz ajena de una serie.
- **Ideas para el próximo paso, sin probar:** usar Silero 0,9 solo para *abrir* la frase y dejar que el RMS la cierre; o un umbral RMS que siga el ruido de fondo (§11.6, paso 2). Cualquiera se confirma con una toma nueva y otra voz antes de tocar la llamada.

10. Límites

- **Una sola voz y un solo lugar:** Luciano, micrófono de la Mac, su pieza y una serie de fondo. 30 frases por toma: una frase equivale a 3,3 puntos. Faltan la condición Meet y otra voz del equipo.
- **El umbral 0,9 se eligió mirando este mismo audio** (simulación de la sección 6). No hay una toma nueva que lo confirme.
- **Demora y costo son offline en la Mac M1** (reloj simulado, ASR con 2 hilos y Silero con 1). No hay mediciones en el teléfono, de batería ni de temperatura. La memoria pico varió entre 870 y 1140 MB sin relación con el detector (Silero pesa 0,6 MB).
- **Una versión de Silero y una forma de usarlo:** el `silero_vad.onnx` del release de sherpa con su histéresis. No se probaron otros modelos, otra histéresis ni combinar los dos detectores.
- La toma 1 de G06 (bloque 6) se borró antes de medir, así que «Compartí pantalla» se midió en dos tomas.

11. Cómo reproducirlo

Desde la raíz del repositorio, con el entorno que tiene sherpa-onnx. Las corridas quedan en `experiments/asr-local/corridas/` y el detalle está en PLAN-VOZ-REAL.md §12:

```
python experiments/asr-local/medir_voz_real.py --solo-parakeet --contra-parakeet parakeet-0.8-rms-0.008 --variantes parakeet-0.9-rms-0.003,parakeet-0.8-silero-0.5,parakeet-0.5-silero-0.5,parakeet-0.3-silero-0.5,parakeet-0.5-silero-0.9,parakeet-0.3-silero-0.9 --pruebas …/llamadas --etiqueta parakeet-silero-vs-rms
python experiments/asr-local/comparar_vad.py --pruebas …/llamadas --corrida experiments/asr-local/corridas/2026-10-29_voz-real_parakeet-silero-vs-rms
python experiments/asr-local/comparar_vad.py --rehacer-resumen --salida experiments/asr-local/corridas/2026-10-29_voz-real_vad-extras --pruebas …/llamadas --corrida … --simular-umbrales 0.5,0.7,0.85,0.9
```

Informe generado con `informe_silero_vs_rms.py` el 2026-10-29.